

# Estatística Computacional

Patrícia de Siqueira Ramos

PPGEAB  
UNIFAL-MG

2 de Maio de 2018

# Métodos para geração de variáveis aleatórias não uniformes

- Transformação inversa (baseado no teorema da probabilidade integral)
- Aceitação-Rejeição
- Composição
- Convolução
- Caracterização

# Métodos para geração de variáveis aleatórias não uniformes

- Realizações de v.a.s de outras distribuições de probabilidade são obtidas pela transformação de sequências de números aleatórios uniformes entre 0 e 1, ou seja,  $U(0,1)$
- Se tivermos números aleatórios uniformes i.i.d. podemos gerar números de muitas outras distribuições

# Geração de realizações de v.a.s usando o R

- O R consegue gerar números de várias distribuições de probabilidade
- Basta acrescentarmos os prefixos:
  - “d” para *density function* (densidade)
  - “p” para *c.d.f.* (função distribuição)
  - “q” para quantis
  - “r” para *random generation* (realizações de v.a.s)

# Algumas das distribuições disponíveis no R

| Distribuição    | Nome    | Parâmetros          |
|-----------------|---------|---------------------|
| beta            | beta    | shape1, shape2, ncp |
| binomial        | binom   | size, prob          |
| Cauchy          | cauchy  | location, scale     |
| $\chi^2$        | chisq   | df, ncp             |
| exponencial     | exp     | rate                |
| $F$             | f       | df1, df2, ncp       |
| gama            | gamma   | shape, scale        |
| geométrica      | geom    | prob                |
| hipergeométrica | hyper   | m, n, k             |
| lognormal       | lnorm   | meanlog, sdlog      |
| logística       | logis   | location, scale     |
| binomial neg.   | nbinom  | size, prob          |
| normal          | norm    | mean, sd            |
| Poisson         | pois    | lambda              |
| $t$ de Student  | t       | df, ncp             |
| uniform         | unif    | min, max            |
| Weibull         | weibull | shape, scale        |

# Método da transformação inversa

# Método da transformação inversa

O método da transformação inversa é baseado no resultado conhecido a seguir:

*Teorema fundamental da transformação de probabilidades: Sejam  $U$  uma variável aleatória uniforme  $U(0,1)$  e  $X$  uma variável aleatória com densidade  $f_X(x)$  e função de distribuição  $F_X(x)$  contínua e invertível, então  $X = F_X^{-1}(U)$  possui densidade  $f_X(x)$ , sendo  $F^{-1}$  a função inversa de  $F$ .*

# Método da transformação inversa

Uma forma mais simples do teorema é:

*Teorema fundamental da transformação de probabilidades: Se  $X$  é uma variável aleatória contínua com função de distribuição  $F_X(x)$ , então  $U = F_X(x) \sim U(0, 1)$ .*



# Método da transformação inversa

Uma prova possível do teorema é:

*Assuma  $F_X$  contínua e crescente. Defina  $U = F_X(x)$  e, sendo  $U \sim U(0,1)$ ,  $U$  assume valores no intervalo  $[0,1]$ . Então:*

$$F_U(x) = P(F_X(x) \leq x) = P(X \leq F_X^{-1}(x)) = F_X(F_X^{-1}(x)) = x.$$

Note que  $F(F^{-1}(x)) = F^{-1}(F(x)) = x$ .

# Método da transformação inversa

- $F_X^{-1}(U)$  possui a mesma distribuição de  $X$
- Então, para gerar uma realização de uma v.a.  $X$ , deve-se primeiro gerar um valor  $u$  a partir de  $U(0, 1)$  e obter  $F_X^{-1}(u)$
- O método é simples de ser aplicado se  $F_X^{-1}$  for fácil de ser obtida
- Pode ser utilizado para variáveis discretas e contínuas (no caso discreto deverá ser feita uma adaptação)
- Algumas distribuições para as quais é possível aplicar o método: exponencial, Weibull, logística, Cauchy
- Para outras, é mais eficiente utilizar outros métodos

# Método da transformação inversa - caso contínuo

Algoritmo:

- 1 Obter a função inversa  $F_X^{-1}(u)$
- 2 Escrever uma função/comando para obter  $F_X^{-1}(u)$
- 3 Para cada valor a ser gerado:
  - Gerar uma observação  $u$  de  $U(0, 1)$
  - Aplicar  $x = F_X^{-1}(u)$

# Método da transformação inversa - caso contínuo

Exemplo 1: Usar o método da transformação inversa para simular uma amostra aleatória da distribuição  $f_X(x) = 3x^2$ ,  $0 < x < 1$ .

Resp.:  $F_X(x) = x^3$ ,  $0 < x < 1$  e  $F_X^{-1}(u) = u^{1/3}$ .

Então é preciso gerar uma sequência de números uniformes, o vetor:

$$\mathbf{u} = u_1, u_2, \dots, u_n,$$

aplicar  $u^{1/3}$  e essa será a amostra:

$$x_1, x_2, \dots, x_n$$

da distribuição desejada  $f_X(x)$ .

# Método da transformação inversa - caso contínuo

Exemplo 1 no R: O histograma e o gráfico esperado para  $f_X(x)$  concordam?

```
n = 1000
u = runif(n) # geração do vetor u
x = u ** (1/3) # transformação
# histograma da amostra
hist(x, prob=TRUE, main=expression(f(x)==lambda*exp(-lambda*x)))
lines(density(x)) # estimação kernel

# para gerar o gráfico da função teórica
y = seq(0, 1, .01)
# curva teórica
lines(y, 3*y**2, col='red')
```

# Método da transformação inversa - caso contínuo

Exemplo 2: Usar o método da transformação inversa para simular uma amostra aleatória da distribuição exponencial. Se  $X \sim \text{exponencial}(\lambda)$ :

$$f_X(x; \lambda) = \lambda e^{-\lambda x}, \quad x > 0, \lambda > 0.$$

# Método da transformação inversa - caso contínuo

Exemplo 2: Usar o método da transformação inversa para simular uma amostra aleatória da distribuição exponencial. Se  $X \sim \text{exponencial}(\lambda)$ :

$$f_X(x; \lambda) = \lambda e^{-\lambda x}, \quad x > 0, \lambda > 0.$$

$$\text{Resp.: } F_X(x) = 1 - e^{-\lambda x} \text{ e } F_X^{-1}(u) = -\frac{1}{\lambda} \ln(1 - u).$$

Dada a simetria da distribuição uniforme, podemos trocar  $1 - u$  por  $u$ .

Dica: página que pode ajudar na obtenção de integrais (e outras funções):  
[www.wolframalpha.com](http://www.wolframalpha.com)

# Método da transformação inversa - caso contínuo

Exemplo 2: Para a exponencial,

- a) Faça o mesmo que foi feito para o exemplo 1 apenas trocando a expressão para obter a amostra  $\mathbf{x}$ . Usar  $\lambda = 2$ , por exemplo.
- b) Compare o resultado obtido (histograma e estimação kernel) com o teórico para a distribuição exponencial, como no exemplo 1.
- c) Crie uma função no R chamada `rexpon(n, lamb)` para gerar uma amostra aleatória da distribuição exponencial usando o método da transformação inversa e retorne os valores gerados (e histogramas) usando  $\lambda = 2$  e  $\lambda = 5$ .
- d) Sabendo que a média da exponencial é  $1/\lambda$ , compare os valores teóricos das médias para  $\lambda = 2$  e  $\lambda = 5$  com os valores obtidos com as amostras da letra c.



# Método da transformação inversa - caso discreto


- Pode-se utilizar o método da transformação inversa também para distribuições discretas
- Se  $X$  é uma v.a. discreta e

$$\cdots < x_{i-1} < x_i < x_{i+1} < \cdots$$

sejam os pontos de descontinuidade de  $F_X(x)$ , então a transformação inversa é  $F_X^{-1}(u) = x_i$ , em que  $F_X(x_{i-1}) < u \leq F_X(x_i)$

# Método da transformação inversa - caso discreto

- 1 Gerar uma observação  $u$  de  $U(0, 1)$
- 2 Encontrar o menor inteiro tal que  $F(x_{i-1}) < u \leq F(x_i)$  e retornar  $x = x_i$



# Método da transformação inversa - caso discreto

Ex. 3: Considere o caso da distribuição Bernoulli:

$$f_X(x; p) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}, \quad 0 \leq p \leq 1$$

$$f_X(x; p) = \begin{cases} 1 - p, & x = 0 \\ p, & x = 1 \end{cases}$$

$$\mu = p$$

$$\sigma^2 = p(1 - p)$$

Sendo  $p = 0,40$ , por exemplo:

| $x$    | 0    | 1    |
|--------|------|------|
| $f(x)$ | 0,60 | 0,40 |

# Método da transformação inversa - caso discreto

Ex. 3: Distribuição Bernoulli:

$$F_X(x; p) = \begin{cases} 0, & x < 0 \\ 1 - p, & 0 \leq x < 1 \\ 1, & x \geq 1 \end{cases}$$

- Nesse exemplo,  $F_X(0) = f_X(0) = 1 - p$  e  $F_X(1) = 1$
- Então,  $F_X^{-1}(u) = 1$  se  $u > 0,6$  e
- $F_X^{-1}(u) = 0$  se  $u \leq 0,6$

# Método da transformação inversa - caso discreto

Ex. 3: Distribuição Bernoulli:

$$F_X(x; p) = \begin{cases} 0, & x < 0 \\ 1 - p, & 0 \leq x < 1 \\ 1, & x \geq 1 \end{cases}$$

- Nesse exemplo,  $F_X(0) = f_X(0) = 1 - p$  e  $F_X(1) = 1$
- Então,  $F_X^{-1}(u) = 1$  se  $u > 0,6$  e
- $F_X^{-1}(u) = 0$  se  $u \leq 0,6$
- Assim, gerar valores da  $U(0, 1)$  e:
  - se  $u \leq 1 - p = 0,6$  será considerado 0
  - se  $u > 1 - p = 0,6$ , será considerado 1 (fazer o gráfico da  $F$  da Bernoulli).

# Método da transformação inversa - caso discreto

## Ex. 3: Bernoulli

```
n = 10    # amostra pequena
p = 0.4
u = runif(n)
u > 0.6    # visualizar o vetor lógico
x = as.integer(u > 0.6)
x
mean(x)    # teórico:  $\mu = p = 0,4$ 
var(x)     # teórico:  $\sigma^2 = p(1-p) = 0,4*0,6 = 0,24$ 

hist(x, breaks=c(-0.5, 0.5, 1.5), prob=T)
# para gerar o gráfico da função do R
y = rbinom(n, size=1, prob=p)
hist(y, breaks = c(-0.5, 0.5, 1.5), prob = T)
# amostra maior
n = 1000
```

# Método da transformação inversa - caso discreto

Ex. 4: Considere a seguinte distribuição de probabilidade discreta:

|        |      |      |      |      |      |
|--------|------|------|------|------|------|
| $x$    | 1    | 2    | 3    | 4    | 5    |
| $f(x)$ | 0,20 | 0,30 | 0,10 | 0,05 | 0,35 |

# Método da transformação inversa - caso discreto

Ex. 4: Considere a seguinte distribuição de probabilidade discreta:

| $x$    | 1    | 2    | 3    | 4    | 5    |
|--------|------|------|------|------|------|
| $f(x)$ | 0,20 | 0,30 | 0,10 | 0,05 | 0,35 |

```
n = 1000
```

```
p = c(0.2, 0.3, 0.1, 0.05, 0.35)
```

```
Fx = cumsum(p)
```

```
u = runif(n)
```

```
x = 1:n
```

```
for(i in 1:n){
```

```
  indice = 1
```

```
  while(u[i] > Fx[indice]){
```

```
    indice = indice + 1
```

```
  }
```

```
  x[i] = indice
```

```
}
```

```
hist(x, breaks = seq(0.5, 5.5))
```

```
hist(x, breaks = seq(0.5, 5.5), prob = T)
```



# Método da aceitação/rejeição

# Método da aceitação/rejeição

- Como vimos, obter uma fórmula explícita para  $F^{-1}$  a partir da função de distribuição de onde queremos gerar realizações de v.a.s nem sempre é possível
- Mesmo se for possível, podem existir alguns métodos mais eficientes para isso
- Um desses métodos é o da aceitação/rejeição ou, simplesmente, método da rejeição

# Método da aceitação/rejeição

- Começamos assumindo que a  $F$  que queremos simular tem f.d.p.  $f$  (caso contínuo, o discreto é similar)
- A ideia é encontrar uma distribuição alternativa  $G$ , com função de densidade  $g$  que:
  - já tenhamos algum método eficiente de geração de v.a.s de  $g$
  - $g$  deve ser próxima de  $f$
- Geralmente, assume-se que a razão  $f_X(x)/g_X(x)$  é limitada por uma constante  $c > 0$ , ou seja,

$$\sup_x \{f(x)/g(x)\} \leq c$$

- Na prática, queremos  $c$  o mais próximo de 1 possível

# Método da aceitação/rejeição

Algoritmo:

- 1 Gerar uma realização  $y$  de  $G$
- 2 Gerar  $u$  de  $U(0, 1)$
- 3 Se

$$u \leq \frac{f(y)}{cg(y)},$$

aceitar  $y$  e fazer  $x = y$ , senão rejeitar  $y$  e repetir os passos

# Método da aceitação/rejeição

- Assim,

$$P(\text{aceitar} | Y) = P\left(U \leq \frac{f(y)}{cg(y)} | Y\right) = \frac{f(y)}{cg(y)}.$$

A última igualdade vale porque estamos avaliando a função distribuição de  $U$ , que é uma  $U(0, 1)$ .

- Dessa forma,

$$0 < \frac{f(y)}{cg(y)} \leq 1.$$

# Método da aceitação/rejeição

- A probabilidade total de aceitação para qualquer iteração é

$$\int P(\text{aceitar}|y)P(Y = y) = \int \frac{f(y)}{cg(y)}g(y) = \frac{1}{c}.$$

- O número de vezes  $N$  que os passos devem ser repetidos (número de iterações para gerar  $X$ ) é uma v.a. que segue a distribuição geométrica com probabilidade de sucesso  $p = \frac{1}{c}$
- Como  $E(N) = 1/p$ , em média, cada valor amostral de  $X$  requer  $c$  iterações

# Método da aceitação/rejeição

Resumindo:

- Devemos escolher uma função  $g$  que minimize a constante  $c$
- A melhor função seria  $g(x) = f(x)$ , que não é o que queremos, pois procuramos uma função  $g$  alternativa a  $f$  que seja fácil de simular
- Requer habilidade encontrar a função  $g$

# Método da aceitação/rejeição

Ex. 5: Considere o caso da distribuição beta. Em média, quantos números deverão ser simulados para gerar 1000 realizações da  $beta(\alpha = 2, \beta = 2)$ , usando o método da aceitação/rejeição?



## Método da aceitação/rejeição

Ex. 5: Considere o caso da distribuição beta. Em média, quantos números deverão ser simulados para gerar 1000 realizações da  $\text{beta}(\alpha = 2, \beta = 2)$ , usando o método da aceitação/rejeição?

Resp.: Sabemos que esse valor dependerá da constante  $c$  que, por sua vez, depende da escolha de  $g$ . A f.d.p. da  $\text{beta}(\alpha = 2, \beta = 2)$  é

$$f(x) = 6x(1 - x), \quad 0 < x < 1.$$

## Método da aceitação/rejeição

Ex. 5 (cont.): Para visualizar o gráfico da f.d.p.  $\text{beta}(2, 2)$ :

```
y = seq(0, 1, length=100)
plot(y, 6*y*(1 - y), type='l')

# ou usando a própria densidade beta do R
curve(dbeta(x, 2, 2), col='red')
```

## Método da aceitação/rejeição

Ex. 5 (cont.): Para visualizar o gráfico da f.d.p.  $\text{beta}(2, 2)$ :

```
y = seq(0, 1, length=100)
plot(y, 6*y*(1 - y), type='l')
```

```
# ou usando a própria densidade beta do R
curve(dbeta(x, 2, 2), col='red')
```

Vamos considerar  $g$  como sendo a  $U(0, 1)$  e  $c = 1,5$ . Então  $y$  será aceita se

$$u \leq \frac{f(y)}{cg(y)} = \frac{6y(1-y)}{1,5 \cdot 1} = 4y(1-y)$$

# Método da aceitação/rejeição

Ex. 5 (cont.): Então, na média,  $c * n = 1500$  iterações (e 3000 números aleatórios) serão necessárias para gerar uma amostra de tamanho 1000.

```
# gerar n observações da B(2,2) usando o método da rejeição
# função g é a U(0,1) e c = 1,5
n = 1000
k = 0      # contador para aceitação
j = 0      # número de iterações
x = numeric(n)
while (k < n) {
  u = runif(1)
  j = j + 1
  y = runif(1) # v.a. de g
  if (u <= 4*y*(1-y)) { # aceitamos y
    k = k + 1
    x[k] = y
  }
}
j # iterações necessárias para n
hist(x, prob = T)
```

# Método da aceitação/rejeição

```
# densidade obtida e a amostra gerada pelo R
lines(density(x), col='blue')
lines(density(rbeta(n,2,2)), col='red')

# comparar quantis empíricos e teóricos
p = seq(.1, .9, .1)
Qhat = quantile(x, p)    # quantis amostrais
Q = qbeta(p, 2, 2)       # quantis teóricos
round(rbind(Qhat, Q), 3)
```

## Método da aceitação/rejeição

*O  $p$ -ésimo percentil ( $0 < p < 1$ ) de uma amostra de tamanho  $n$  é assintoticamente distribuído como uma normal com média igual ao  $p$ -ésimo percentil da distribuição de origem e com variância igual a*

$$V[X_p] = \frac{p(1-p)}{n \cdot f(Q_p)^2}.$$

*Assim, o erro padrão da estimativa do percentil é*

$$EP[X_p] = \frac{\sqrt{p(1-p)}}{\sqrt{n} \cdot f(Q_p)}.$$

# Método da aceitação/rejeição

```
# incluir o erro padrão das estimativas dos quantis  
ep = sqrt(p * (1 - p)) / (sqrt(n) * dbeta(Q, 2, 2))  
round(rbind(Qhat, Q, ep), 3)
```

Repetir para  $n = 10000$  e ver que as estimativas ficam mais precisas.

# Exercício

Suponha que queremos gerar uma v.a.  $\text{gama}(\alpha, \beta)$ . A função de distribuição da gama é

$$F_X(x; \alpha, \beta) = \int_0^x \frac{\beta e^{-\beta t} (\beta t)^{\alpha-1}}{(\alpha-1)!} dt.$$

Não é possível obter uma expressão fechada para sua inversa. Mas podemos usar o seguinte resultado:

*Uma v.a.  $X \sim \text{gama}(\alpha, \beta)$  = soma de  $\alpha$  v.a.s exponenciais independentes,  $\exp(\beta)$ .*

O que precisamos fazer é:

- 1 Gerar  $\alpha$  números aleatórios  $u_1, u_2, \dots, u_\alpha$
- 2 Fazer  $x = -\frac{1}{\beta} \ln u_1 - \dots - \frac{1}{\beta} \ln u_\alpha = -\frac{1}{\beta} \ln(u_1 \dots u_\alpha)$ , pois  $\sum_{i=1}^n \ln x_i = \ln(x_1 \dots x_n)$

Então, usando esses passos, gere uma amostra de tamanho  $n = 1000$  da  $\text{gama}(\alpha = 2, \beta = 2)$ , gere o histograma, a estimação kernel e compare com a distribuição teórica (gráfico, média e variância).