

# Estatística Computacional

Patrícia de Siqueira Ramos

PPGEAB  
UNIFAL-MG

9 de Maio de 2018

## Outras transformações

Há outras transformações, além da transformação inversa, que podem ser utilizadas para simular variáveis aleatórias:

1) Se  $Z \sim N(0, 1)$ , então

$$V = Z^2 \sim \chi^2(1)$$

## Outras transformações

Há outras transformações, além da transformação inversa, que podem ser utilizadas para simular variáveis aleatórias:

1) Se  $Z \sim N(0, 1)$ , então

$$V = Z^2 \sim \chi^2(1)$$

2) Se  $V \sim \chi^2(m)$  e  $W \sim \chi^2(n)$  são independentes, então

$$F = \frac{V/m}{W/n} \sim F_{m,n}$$

## Outras transformações

Há outras transformações, além da transformação inversa, que podem ser utilizadas para simular variáveis aleatórias:

1) Se  $Z \sim N(0, 1)$ , então

$$V = Z^2 \sim \chi^2(1)$$

2) Se  $V \sim \chi^2(m)$  e  $W \sim \chi^2(n)$  são independentes, então

$$F = \frac{V/m}{W/n} \sim F_{m,n}$$

3) Se  $Z \sim N(0, 1)$  e  $V \sim \chi^2(n)$  são independentes, então

$$T = \frac{Z}{\sqrt{V/n}} \sim t_n$$

## Outras transformações

4) Se  $U, V \sim U(0, 1)$  são independentes, então

$$Z_1 = \sqrt{-2 \log U} \cos(2\pi V)$$

$$Z_2 = \sqrt{-2 \log V} \sin(2\pi U)$$

são variáveis normais padrão independentes (algoritmo Box-Müller)

## Outras transformações

4) Se  $U, V \sim U(0, 1)$  são independentes, então

$$Z_1 = \sqrt{-2 \log U} \cos(2\pi V)$$

$$Z_2 = \sqrt{-2 \log V} \sin(2\pi U)$$

são variáveis normais padrão independentes (algoritmo Box-Müller)

5) Se  $U \sim \text{gama}(r, \lambda)$  e  $V \sim \text{gama}(s, \lambda)$  são independentes, então

$$X = \frac{U}{U + V} \sim \text{beta}(r, s)$$

## Outras transformações

4) Se  $U, V \sim U(0, 1)$  são independentes, então

$$Z_1 = \sqrt{-2 \log U} \cos(2\pi V)$$

$$Z_2 = \sqrt{-2 \log V} \sin(2\pi U)$$

são variáveis normais padrão independentes (algoritmo Box-Müller)

5) Se  $U \sim \text{gama}(r, \lambda)$  e  $V \sim \text{gama}(s, \lambda)$  são independentes, então

$$X = \frac{U}{U + V} \sim \text{beta}(r, s)$$

6) Se  $U, V \sim U(0, 1)$  são independentes, então

$$X = \left\lfloor 1 + \frac{\log V}{\log(1 - (1 - \theta)^U)} \right\rfloor \sim \text{logaritmica}(\theta),$$

em que  $\lfloor x \rfloor$ : parte inteira de  $x$ .

## Outras transformações

Exemplo 6: Já vimos um gerador de realizações de v.a.s *beta* usando o método da aceitação/rejeição. A relação (5) entre as distribuições *gama* e *beta* provê outro gerador:

Se  $U \sim \text{gama}(r, \lambda)$  e  $V \sim \text{gama}(s, \lambda)$  são independentes, então

$$X = \frac{U}{U + V} \sim \text{beta}(r, s).$$



## Outras transformações

Exemplo 6: Já vimos um gerador de realizações de v.a.s *beta* usando o método da aceitação/rejeição. A relação (5) entre as distribuições *gama* e *beta* provê outro gerador:

Se  $U \sim \text{gama}(r, \lambda)$  e  $V \sim \text{gama}(s, \lambda)$  são independentes, então

$$X = \frac{U}{U + V} \sim \text{beta}(r, s).$$

Essa transformação permite criar o algoritmo para gerar realizações *beta*( $a, b$ ):

- 1 Gerar uma realização  $u$  de *gama*( $a, \lambda$ )
- 2 Gerar uma realização  $v$  de *gama*( $b, \lambda$ )
- 3 Fazer  $x = \frac{u}{u + v}$

# Outras transformações

Exemplo 6 no R: Gerar a.a. da  $\text{beta}(3, 2)$

```
n = 1000
a = 3
b = 2
lambda = 1
u = rgamma(n, shape = a, rate = lambda)
v = rgamma(n, shape = b, rate = lambda)
x = u/(u + v)
x
hist(x, prob = T)
# densidade obtida e a amostra gerada pelo R - rbeta
lines(density(x), col = "blue")
lines(density(rbeta(n, a, b)), col = 'red')
# QQ plot da beta(3,2)
qqplot(qbeta(ppoints(n), a, b), x,
       cex = 0.25, main = 'QQ plot da beta(3,2)',
       xlab = 'quantis teóricos', ylab = 'quantis amostrais')
qqline(x, distribution = function(p) qbeta(p,a,b))

# ppoints(n): função do R que calcula o vetor de n posições
# p[i] = (i - 3/8)/(n + 1/4)
```

## Outras transformações

Exemplo 7: A relação (6) entre as distribuições uniforme e logarítmica é:

Se  $U, V \sim U(0, 1)$  são independentes, então

$$X = \left\lfloor 1 + \frac{\log V}{\log(1 - (1 - \theta)^U)} \right\rfloor \sim \text{logarítmica}(\theta).$$

Algoritmo para gerar realizações da distribuição logarítmica( $\theta$ ):

- 1 Gerar uma realização  $u$  de  $U(0, 1)$
- 2 Gerar uma realização  $v$  de  $U(0, 1)$
- 3 Fazer  $x = \lfloor (1 + \log v) / \log(1 - (1 - \theta)^u) \rfloor$

# Outras transformações

Exemplo 7 no R:

```
n = 1000
theta = 0.5
u = runif(n)
v = runif(n)
x = floor(1 + log(v)/log(1 - (1 - theta) ** u))
hist(x, prob = T, breaks = seq(0.5, max(x) + 0.5))

# comparar com resultado teórico
k = 1:max(x)
p = -1 / log(1 - theta) * theta ** k / k # f(x) teórica
pch = tabulate(x)/n                      # observada
round(rbind(pch, p), 3)
```

# Outras transformações

Exemplo 7 no R por meio de uma função que retorna a amostra da distribuição logarítmica:

```
rlogaritmica = function(n, theta) {  
  stopifnot(theta > 0 & theta < 1)  
  u = runif(n)  
  v = runif(n)  
  x = floor(1 + log(v)/log(1 - (1 - theta) ** u))  
  return(x)  
}  
  
x = rlogaritmica(1000, theta)  
hist(x, prob = T, breaks = seq(0.5, max(x) + 0.5))
```

# Método da convolução (soma) e misturas

- Somas e misturas de variáveis aleatórias são tipos especiais de transformações
- Primeiro trataremos da soma de v.a.s independentes (convoluções) e alguns exemplos

*Sejam  $X_1, \dots, X_n$  v.a.s independentes e identicamente distribuídas e seja  $S = X_1 + \dots + X_n$ . A função distribuição da soma  $S$  é chamada convolução de grau  $n$  de  $X$  e denota-se  $F_n^{*(n)}$ . Assim, para simular uma convolução, basta gerar  $X_1, \dots, X_n$  e obter a soma.*

# Convolução

Muitas distribuições são obtidas por convolução. Alguns exemplos incluem:

- A convolução de  $n$  v.a.s  $Bernoulli(p)$  tem distribuição  $bin(n, p)$
- Se  $\nu > 0$  é um inteiro, a distribuição  $\chi^2$  com  $\nu$  g.l. é a convolução de  $\nu$  variáveis normais padrão i.i.d. ao quadrado
- A distribuição binomial negativa  $binN(r, p)$  é a convolução de  $r$  variáveis aleatórias geométricas,  $geom(p)$ , i.i.d.
- A convolução de  $r$  variáveis aleatórias i.i.d.  $exp(\lambda)$  tem distribuição  $gama(r, \lambda)$

Obviamente, é mais fácil usar as funções `rchisq`, `rgeom`, `rnbinom` etc. para gerar a.a. dessas distribuições ( $\chi^2$ ,  $binN$ ,  $geom$  etc.), mas vamos ilustrar sua obtenção pelo método da convolução.

# Convolução

Exemplo 8: Este exemplo gera uma amostra da  $\chi^2(\nu)$  a partir do quadrado de  $\nu$  normais. Se  $Z_1, \dots, Z_\nu$  são v.a.s  $N(0, 1)$  i.i.d., então  $V = Z_1^2 + \dots + Z_\nu^2$  tem distribuição  $\chi^2(\nu)$ .

Passos para gerar uma amostra de tamanho  $n$  da  $\chi^2(\nu)$ :

- 1 Preencha uma matriz  $n \times \nu$  com  $n\nu$  variáveis  $N(0, 1)$
- 2 Eleve ao quadrado cada valor da matriz
- 3 Obtenha as somas das linhas das normais ao quadrado. Cada soma de linha será uma observação aleatória da  $\chi^2(\nu)$
- 4 Retorne o vetor das somas das linhas



# Convolução

Exemplo 8 no R:

```
n = 1000
nu = 2
Z = matrix(rnorm(n*nu), n, nu) ** 2 # matriz de N(0,1)
v = rowSums(Z) # soma das linhas - método 1
v = apply(Z, 1, sum) # soma das linhas - método 2

# conferindo
mean(v) # E(V) = nu
mean(v ** 2) # E(V**2) = 2nu + nu**2
var(v) # V(V) = 2nu
```

# Misturas

*Uma v.a.  $X$  é uma mistura discreta de modelos se*

$$F_X(x) = \sum_{i=1}^k \theta_i F_i(x), \text{ com } \theta_i > 0 \text{ e } \sum_{i=1}^k \theta_i = 1,$$

*em que as constantes  $\theta_i$  são chamadas pesos ou probabilidades da mistura (notação parecida com convolução, mas as distribuições são diferentes).*

*Uma v.a.  $X$  é uma mistura contínua de modelos se*

$$F_X(x) = \int_{-\infty}^{\infty} F_{X|Y=y}(x) f_Y(y) dy, \text{ com } f_Y(y) > 0 \text{ e } \int_{-\infty}^{\infty} f_Y(y) dy = 1,$$

*em que  $f_Y(y)$  é a função peso.*

# Misturas

Exemplo 9: Compare os métodos de simulação de uma convolução e de uma mistura de variáveis normais. Suponha  $X_1 \sim N(0, 1)$  e  $X_2 \sim N(3, 1)$  independentes.

$S = X_1 + X_2$  denota a convolução. A distribuição de  $S$  é normal com média  $\mu_1 + \mu_2 = 3$  e variância  $\sigma_1^2 + \sigma_2^2 = 2$ .

Passos para simular a convolução:

- 1 Gerar  $x_1 \sim N(0, 1)$
- 2 Gerar  $x_2 \sim N(3, 1)$
- 3 Retornar  $s = x_1 + x_2$

# Misturas

Exemplo 9 (cont.): Podemos definir uma mistura normal 50%, denotada por  $F_X(x) = 0,5F_{X_1}(x) + 0,5F_{X_2}(x)$ . Diferente da convolução anterior, a distribuição da mistura é não normal, é bimodal.

Passos para simular a mistura:

- 1 Gerar um inteiro  $k \in \{1, 2\}$ , em que  $P(1) = P(2) = 0,50$
- 2 Se  $k = 1$ , gerar  $x_1 \sim N(0, 1)$
- 3 Se  $k = 2$ , gerar  $x_2 \sim N(3, 1)$

# Misturas

Exemplo 10: Sejam  $X_1 \sim \text{gama}(2, 2)$  e  $X_2 \sim \text{gama}(4, 2)$  independentes. Compare os histogramas das amostras geradas pela convolução

$$S = X_1 + X_2$$

# Misturas

Exemplo 10: Sejam  $X_1 \sim \text{gama}(2, 2)$  e  $X_2 \sim \text{gama}(4, 2)$  independentes. Compare os histogramas das amostras geradas pela convolução

$$S = X_1 + X_2$$

Se  $X_1 \sim \text{gama}(r, \lambda)$  e  $X_2 \sim \text{gama}(s, \lambda)$ , então

$$S = X_1 + X_2 \sim \text{gama}(r + s, \lambda).$$

e pela mistura

$$F_X(x) = 0,5F_{X_1}(x) + 0,5F_{X_2}(x).$$

# Misturas

Exemplo 10 no R:

```
n = 1000
r = 2; s = 4; lambda = 2
x1 = rgamma(n, r, lambda) # gama(2,2)
x2 = rgamma(n, s, lambda) # gama(4,2)
s = x1 + x2                # a convolução
u = runif(n)
k = sample(0:1, n, replace = T)
x = k * x1 + (1 - k) * x2 # a mistura

par(mfrow=c(1,2))          # dois gráficos em uma visualização
hist(s, prob=TRUE)
hist(x, prob=TRUE)

# gama(r,lambda) + gama(s,lambda) = gama(r+s,lambda)
# densidade obtida de s e a amostra gerada pelo R
par(mfrow=c(1,1))          # voltar a ser 1 gráfico
plot(density(s), col = "blue")
lines(density(rgamma(n, r+s, lambda)), col='red')
```

## Exercício

Implementar no R o ex. 9 (convolução e mistura de duas normais).

a) Compare as duas distribuições obtidas (de  $S$  e de  $X$ ) por meio dos histogramas dispostos lado a lado.

b) Obtenha os QQplots para as variáveis  $S$  e  $X$ . Elas parecem seguir a distribuição normal? Os comandos

```
qqnorm(x);qqline(x)
```

constroem o QQplot da amostra  $x$ .

c) Obtenha a média e a variância da variável  $S$  obtida e compare seus valores com o que seria esperado.

d) Compare a densidade de  $S$  com a obtida gerando-se valores da normal com os parâmetros  $\mu$  e  $\sigma$  adequados (atenção, pois `rnorm` possui como parâmetros a média e o desvio padrão).